Clasificación Automática de Retinopatía Diabética

Pipeline Completo de Clasificación por Gradación de Severidad

Asignatura: Procesamiento de Imagen en Medicina

Curso académico: 2025 – 2026

Fecha de entrega: 24 de abril de 2026

Integrantes del grupo

Javier García Fernández

Miguel Ángel Véliz Ayala

Martín Solano Martínez

Resumen

Este trabajo aborda la clasificación automática de la retinopatía diabética (RD) en cinco grados de severidad clínica, desde grado 0 (sin RD) hasta grado 4 (proliferativa), a partir del dataset público APTOS 2019. Se construye un pipeline completo basado en EfficientNetBN-B3 (MONAI) con preprocesamiento específico para retinografías mediante máscara circular y CLAHE, y se diseñan y comparan diez experimentos que abordan las principales limitaciones del modelo base: desbalance de clases (Exp. A), radiómica cuantitativa con PyRadiomics (Exp. B), clasificación zero-shot con BiomedCLIP (Exp. C), pipelines jerárquicos (Exp. D y E), regresión ordinal a 384 px con optimización de umbrales (Exp. F), corrección de *shortcut learning* mediante preprocesado Ben Graham (Exp. G), fusión multimodal CNN + radiómica con LightGBM (Exp. I) y preentrenamiento en APTOS 2015 (Exp. J). La métrica principal es el kappa cuadrático ponderado (κ^2), estándar en la literatura de gradación automática de RD.

Los resultados demuestran que el preentrenamiento masivo en APTOS 2015 (Exp. J) alcanza el máximo rendimiento global con un κ^2 de 0.8849, estableciendo un modelo altamente robusto ante la variabilidad de las imágenes. Por otro lado, la estrategia jerárquica en etapas (Exp. D) destaca como la solución más eficaz para mejorar la precisión diagnóstica individual, logrando el F1-score más alto (0.63) y optimizando significativamente la detección de las clases críticas (G4). Cabe destacar que, aunque ciertos experimentos no supusieron saltos cuantitativos drásticos en el kappa global, su valor reside en una optimización estratégica que refuerza la consistencia diagnóstica y la fiabilidad en la detección de los estadios más graves de la enfermedad.

Índice

Resumen **i**

Índice **ii**

1. Introducción **1**

2. Estado del arte **3**

2.1. ¿Qué se observa en una retinografía? 3

2.2. ¿Por qué κ^2 y F1 macro? 3

2.3. De la radiómica al deep learning 3

2.4. Regresión ordinal 3

2.5. Zero-shot, interpretabilidad y fusión 4

3. Objetivos y metodología **4**

3.1. Objetivos del proyecto 4

3.2. Dataset: APTOS 2019 y APTOS 2015 4

3.3. Pipeline de Preprocesamiento Común 5

3.4. Data Augmentation 5

3.5. Métricas de Evaluación 6

3.6. Baseline: EfficientNet-B3 con CrossEntropy Ponderada 6

3.7. Configuración de Experimentos (Exp. A–J) 6

3.8. Interpretabilidad: Grad-CAM 7

4. Resultados **7**

4.1. Baseline 8

4.2. Exp. A — Sobremuestreo 8

4.3. Exp. D y E — Pipelines jerárquicos 9

4.4. Exp. C — BiomedCLIP zero-shot 9

4.5. Exp. F — 384 px + Regresión ordinal 9

4.6. Exp. G — Ben Graham + máscara dura 10

4.7. Exp. B — Radiómica + Regresión Logística L1 11

4.8. Exp. I — Fusión CNN + Radiómica 11
4.9. Exp. J — Preentrenamiento con APTOS 2015 11
4.10. Comparativa final 12

5. Conclusiones y vías futuras **13**
5.1. Conclusiones 13
5.2. Limitaciones 13
5.3. Vías futuras 13

Bibliografía **14**

A. Tabla de contribución individual **16**

1. Introducción

La **retinopatía diabética** (RD) es una complicación microvascular de la diabetes mellitus y una de las principales causas de ceguera prevenible en el mundo. Con más de 540 millones de adultos diabéticos estimados en 2023 y una prevalencia de afectación retiniana en torno al 35 % de los pacientes [1], [2], el cribado masivo mediante retinografías de fondo de ojo es una necesidad clínica de primer orden. Sin embargo, la revisión manual de miles de imágenes por oftalmólogos resulta inviable a gran escala, lo que motiva el desarrollo de sistemas automáticos de gradación. Además, estos sistemas no solo permiten escalar el cribado, sino que también facilitan y agilizan el trabajo del personal sanitario, sirviendo como herramienta de apoyo en la clasificación de la enfermedad y en la toma de decisiones clínicas. En este contexto, se emplea el dataset público APTOS 2019, ampliamente utilizado en la literatura, que contiene retinografías etiquetadas según el grado de severidad de la enfermedad, lo que permite evaluar de forma objetiva el rendimiento de los modelos propuestos.

La enfermedad progresa en cinco estadios (Tabla 1): desde la ausencia de lesiones (G0) hasta la neovascularización proliferativa con riesgo de ceguera súbita (G4), pasando por microaneurismas aislados (G1), hemorragias y exudados duros (G2) y afectación vascular extensa en los cuatro cuadrantes (G3). Esta naturaleza ordinal del problema, junto con el severo desbalance de clases del dataset —G0 representa ∼49 % del entrenamiento frente al ∼5 % de G3—, la ambigüedad entre grados adyacentes, la pérdida de detalles finos al comprimir las imágenes a baja resolución y el riesgo de *shortcut learning* sobre artefactos de adquisición, conforman los desafíos técnicos que este proyecto aborda de forma sistemática.

Cuadro 1. Escala de severidad de la retinopatía diabética.

Grado	Nombre	Características clínicas
0	Sin RD	Fondo de ojo normal. Sin lesiones visibles.
1	Leve	Microaneurismas aislados.
2	Moderada	Hemorragias, exudados duros y anomalías vasculares.
3	Severa	Múltiples hemorragias, *venous beading* e IRMA en los cuatro cuadrantes.
4	Proliferativa	Neovascularización con riesgo de hemorragia vítrea y desprendimiento de retina.

El objetivo del proyecto es construir un pipeline reproducible y clínicamente interpretable que parta de un baseline sólido (EfficientNetBN-B3, APTOS 2019, 224 px) y lo mejore de forma justificada mediante diez experimentos que atacan cada una de las debilidades identificadas. Para ello, se emplea el dataset público APTOS 2019, compuesto por retinografías etiquetadas en cinco grados de severidad, lo que permite abordar el problema en un entorno realista y con datos clínicamente relevantes. La métrica principal es el **kappa cuadrático ponderado** (κ^2), que penaliza los errores proporcionalmente al cuadrado de la distancia ordinal entre grados, alineándose con la relevancia clínica de cada tipo de error. La elección de la RD como problema de estudio responde, además, a la disponibilidad de datos públicos de calidad (licencia CC BY 4.0) y a que su naturaleza permite aplicar directamente las técnicas del curso: preprocesamiento de imagen médica, aprendizaje profundo con MONAI, radiómica cuantitativa e interpretabilidad con Grad-CAM.

Figura 1. Retinografías representativas por grado de severidad (G0–G4). Las diferencias entre grados adyacentes son sutiles, lo que dificulta la gradación manual a gran escala.

El resto del documento se organiza del siguiente modo: la Sección 2 revisa el estado del arte; la Sección 3 describe los objetivos, el dataset y el pipeline; la Sección 4 presenta los resultados; y la Sección 5 recoge las conclusiones y vías futuras.

2. Estado del arte

2.1. ¿Qué se observa en una retinografía?

La gradación de la RD sigue la escala ICDR [3], que clasifica según las lesiones visibles en el fondo de ojo: microaneurismas (G1), hemorragias y exudados (G2), anomalías venosas extensas (G3) y neovascularización (G4). Un detalle clave es que los microaneurismas miden entre 15 y 100 μm, lo que a 224 px de resolución se traduce en apenas 1–3 píxeles — de ahí la decisión de subir a 384 px en el Exp. F.

2.2. ¿Por qué κ^2 y F1 macro?

El *accuracy* clásico no sirve aquí por dos razones. Primera: las clases tienen un **orden clínico** — confundir G0 con G4 es mucho más grave que confundirlo con G1. El kappa cuadrático ponderado [4] captura esto penalizando más los errores a mayor distancia ordinal, y es la métrica oficial de APTOS 2019 [5]. Segunda: el **desbalance** (G0 es el 49 %, G3 apenas el 5 %) hace que un modelo que prediga siempre "sano" tenga un accuracy aparentemente bueno pero sea clínicamente inútil. El F1 macro [6] complementa al kappa detectando cuándo el modelo falla en las clases minoritarias.

2.3. De la radiómica al deep learning

Los primeros sistemas automáticos segmentaban lesiones con filtros morfológicos y las clasificaban con SVM [7]: interpretables pero frágiles. La **radiómica** [8] mejoró este enfoque extrayendo cientos de descriptores de textura (GLCM, GLRLM, GLSZM) con herramientas como PyRadiomics [9]. *Es la base del Exp. B.*

El salto real llegó con el deep learning. Gulshan et al. [10] demostraron que una CNN puede igualar a oftalmólogos en la detección de RD, y Ting et al. [11] lo confirmaron a gran escala. De la literatura y de los ganadores de APTOS 2019 adoptamos tres elementos: el backbone **EfficientNet** [12] por su buena relación precisión/coste, el framework **MONAI** [13] para imagen médica, y la normalización de **Ben Graham** [14] que resta la iluminación de fondo para quedarse solo con las microestructuras — *motiva el Exp. G.*

2.4. Regresión ordinal

Entrenar con CrossEntropy y evaluar con κ^2 es contradictorio: la CrossEntropy trata las clases como independientes, pero κ^2 penaliza según la distancia ordinal. La solución es la **regresión ordinal** [15], [16]: una sola neurona de salida que predice un número continuo (G0=0, ..., G4=4) con MSELoss, cuya forma $(\hat{y} - y)^2$ coincide con la

ponderación de κ^2. La salida se discretiza con umbrales optimizados por Nelder-Mead. *Sustenta el Exp. F.*

2.5. Zero-shot, interpretabilidad y fusión

BiomedCLIP [17] permite clasificar sin entrenar, comparando la imagen con descripciones textuales de cada grado — *Exp. C.* **Grad-CAM** [18] visualiza qué regiones activan la red, permitiendo detectar si el modelo mira las lesiones o explota artefactos (*shortcut learning* [19]) — *comparación Exp. F vs. G.* La **fusión CNN + radiómica** con LightGBM [20] combina patrones profundos con textura interpretable — *Exp. I.*

3. Objetivos y metodología

3.1. Objetivos del proyecto

El objetivo general es construir un pipeline completo, reproducible y clínicamente interpretable para la gradación automática de la RD. Para estructurarlo, se descompone en cinco objetivos específicos:

O1. Implementar un **baseline sólido** que sirva de referencia cuantitativa: EfficientNetBN-B3 sobre APTOS 2019 a 224 px con CrossEntropy ponderada.

O2. Identificar de forma iterativa las **debilidades** de cada modelo —empezando por el baseline (desbalance, resolución insuficiente, pérdida desalineada con la métrica) y continuando con las limitaciones que revelan los propios experimentos (e.g., el análisis Grad-CAM del Exp. F motiva el Exp. G)— y diseñar una solución específica para cada una.

O3. Contrastar **paradigmas clásicos y modernos** (radiómica interpretable vs. CNN supervisada vs. zero-shot visión–lenguaje) para cuantificar la aportación real del deep learning sobre el problema.

O4. Validar la **interpretabilidad clínica** del modelo mediante Grad-CAM, garantizando que las activaciones caen sobre estructuras retinianas reales y no sobre artefactos de adquisición.

3.2. Dataset: APTOS 2019 y APTOS 2015

El estudio utiliza como fuente principal **APTOS 2019**, que contiene 3 662 retinografías capturadas en clínicas rurales de la India. Presenta una alta variabilidad en iluminación y resolución, con etiquetas de severidad (0–4) asignadas por expertos. Com-

plementariamente, se emplea **APTOS 2015** (∼35 126 imágenes) para preentrenamiento en el Exp. J debido al *domain shift* existente entre ambos.

Cuadro 2. Distribución de clases y particiones (*splits*) en el dataset APTOS 2019.

Split	G0 (Sano)	G1 (Leve)	G2 (Mod.)	G3 (Sev.)	G4 (Prolif.)	Total
Train	1 434	300	808	154	234	2 930
Val.	172	40	104	22	28	366
Test	199	30	87	17	33	366
Total Global	**1 805**	**370**	**999**	**193**	**295**	**3 662**
% Global	**49,3 %**	**10,1 %**	**27,3 %**	**5,3 %**	**8,1 %**	**100 %**

3.3. Pipeline de Preprocesamiento Común

Para homogeneizar el aspecto visual y eliminar variantes irrelevantes, se aplica:

1. **Máscara circular:** Detección del *bounding box* en el canal verde y aplicación de máscara circular para eliminar bordes negros no informativos (*shortcuts*).
2. **CLAHE:** Aplicado sobre el canal L (espacio LAB) con *clipLimit*=2,0 y *tiles* de 8×8 para mejorar el contraste local de microaneurismas sin amplificar ruido (Mejora de SNR/CNR).
3. **Resize:** Reducción a 224 px (baseline, A–E) o 384 px (F en adelante) mediante interpolación *INTER_AREA*.
4. **Normalización ImageNet:** Normalización con media y desviación típica estándar de ImageNet para compatibilidad con los pesos preentrenados del backbone.

Nota: El Exp. G sustituye CLAHE por la normalización de Ben Graham.

3.4. Data Augmentation

La aumentación de datos amplía la diversidad efectiva del dataset, pero en imagen médica no todas las transformaciones son válidas: aplicar operaciones que generen imágenes anatómicamente imposibles puede confundir al modelo en lugar de ayudarlo. Por ello, la estrategia es deliberadamente conservadora y solo incluye transformaciones que preservan la semántica clínica de la retinografía.

- **Transformaciones aplicadas:** Flip horizontal ($p = 0{,}5$), rotación continua ($\pm 20°$), zoom (0,9–1,1), ruido gaussiano ($\sigma = 0{,}03$) y ajuste de contraste ($\gamma \in [0{,}8,\ 1{,}2]$).

3.5. Métricas de Evaluación

- **Kappa cuadrático ponderado (κ^2):** Métrica principal para gradación ordinal. Penaliza errores según el cuadrado de la distancia:

$$\kappa^2 = 1 - \frac{\sum_{i,j} w_{ij} O_{ij}}{\sum_{i,j} w_{ij} E_{ij}}, \quad w_{ij} = \frac{(i-j)^2}{(N-1)^2} \tag{1}$$

- **F1-score macro:** Media no ponderada para detectar fallos en clases minoritarias (G1, G3).

La evaluación final se realiza exclusivamente sobre el set de test, inaccesible durante la optimización.

3.6. Baseline: EfficientNet-B3 con CrossEntropy Ponderada

El baseline reproduce la configuración estándar de la Práctica 04 del curso, que sirve como punto de partida sólido. Consiste en un backbone *EfficientNet-B3* (MONAI) preentrenado en ImageNet con entrada a 224×224 px, cabeza lineal de 5 neuronas + softmax para clasificación multiclase, y *Weighted CrossEntropy* con pesos inversamente proporcionales a la frecuencia de clase como función de pérdida. Se entrena con Adam ($lr = 10^{-4}$) durante 20 épocas, seleccionando el mejor checkpoint por κ^2 sobre validación.

3.7. Configuración de Experimentos (Exp. A–J)

Cada experimento responde a una limitación concreta del baseline o de un experimento previo. La Tabla 3 resume el problema que ataca y la intervención técnica; las secciones de resultados desarrollan cada uno en detalle.

Cuadro 3. Resumen de experimentos: problema que atacan y acción realizada.

Exp.	Problema	Acción
A	Desbalance de clases	Sobremuestreo de clases minoritarias con *WeightedRandomSampler* para forzar *batches* balanceados.
B	¿Basta la textura sin DL?	107 features radiómicas (PyRadiomics) + Regresión Logística L1 como baseline interpretable.
C	¿Cuánto aporta el DL?	Clasificación zero-shot con BiomedCLIP mediante *prompts* textuales, sin entrenamiento en APTOS.
D	Confusión Sano/Patológico	Pipeline en dos etapas: binario G0 vs resto, seguido de clasificador de severidad G1–G4.
E	Confusión entre grados	Árbol jerárquico de 3 niveles: ¿Sano? → ¿Mild/Severe? → Grado final.
F	Resolución + pérdida	Subir a 384 px y sustituir CrossEntropy por regresión ordinal (MSELoss + umbrales Nelder-Mead).
G	Análisis Grad-CAM de F	Preprocesado Ben Graham (sustracción de media local) + máscara dura + augmentaciones solo fotométricas.
I	CNN y radiómica complementarias	Fusión de 1 536 deep features (Exp. G) + 107 radiómicas → LightGBM y LR L1.
J	Escasez de datos	Preentrenamiento en las 35 k imágenes de APTOS 2015, seguido de *fine-tuning* en 2019.

3.8. Interpretabilidad: Grad-CAM

Para validar clínicamente el modelo, se utiliza **Grad-CAM**, visualizando los mapas de activación de la última capa convolucional. El objetivo es comprobar si la red "mira"las hemorragias y exudados o si utiliza artefactos (bordes, iluminación) como atajos de aprendizaje.

4. Resultados

Todos los valores reportados corresponden al conjunto de test, que permanece inaccesible durante el entrenamiento y la optimización de hiperparámetros. Valores de κ^2 por encima de 0,85 se consideran profesionalmente competentes según el estándar de

APTOS 2019.

4.1. Baseline

El modelo base alcanza $\kappa^2 = 0{,}862$ y F1 macro = 0,602. Partimos de un buen modelo: el kappa alto indica que **ordena bien la gravedad** —los errores que comete sitúan las predicciones en clases próximas a la real, no en extremos opuestos—. Sin embargo, el F1 moderado revela que **no es tan bueno acertando la etiqueta exacta**. Al inspeccionar la matriz de confusión se confirma que las confusiones se concentran entre grados adyacentes (G0↔G1, G2↔G3), lo que es síntoma directo del desbalance de clases y, posiblemente, de una resolución insuficiente para captar los detalles finos que distinguen grados contiguos.

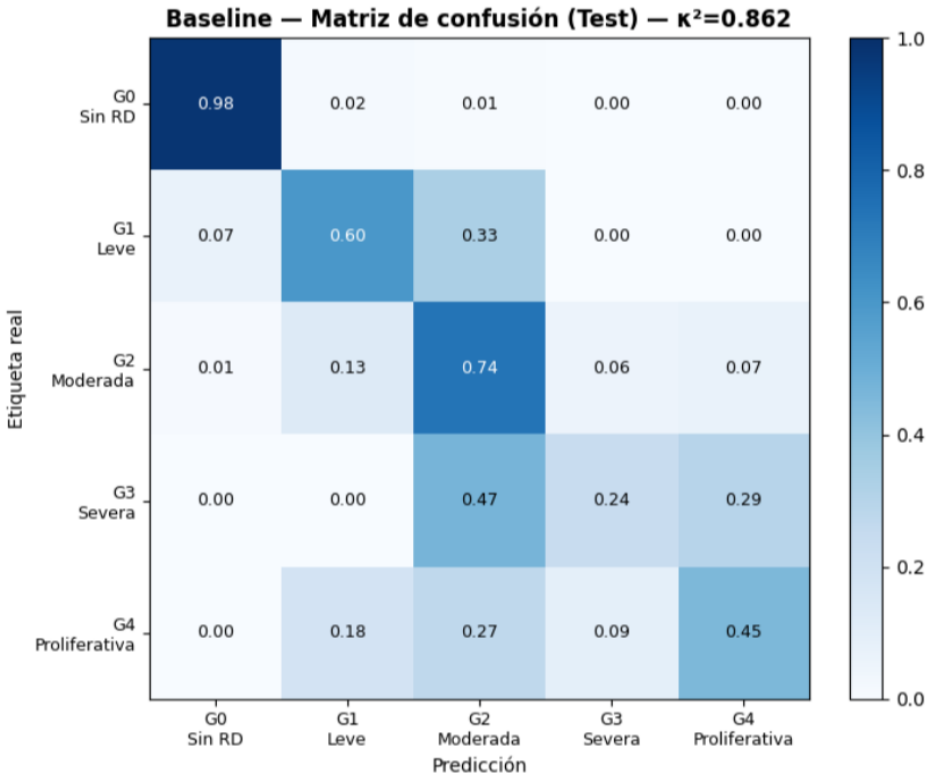

Figura 2. Matriz de confusión del Baseline

4.2. Exp. A — Sobremuestreo

$\kappa^2 = 0{,}880$ F1 = 0,631

El gran beneficiario es **G2 (Moderada)**, que sube de F1 = 0,715 a 0,775: al disponer de más muestras de clases minoritarias, el modelo se atreve con predicciones que antes evitaba, dejando de refugiarse en G0 como clase segura. El kappa sube ligeramente respecto al baseline y el F1 macro mejora al ganar sensibilidad en varias clases. No obstante, G3 apenas mejora (0,276 → 0,286), lo que sugiere que la resolución de 224 px

sigue siendo insuficiente para captar las diferencias sutiles que definen este grado.

4.3. Exp. D y E — Pipelines jerárquicos

	κ^2	F1 macro
D — Dos etapas	0,860	**0,631**
E — Tres niveles	0,855	0,602

Los Exp. D y E representan un cambio de estrategia: pasar de un modelo único a una estructura jerárquica de "divide y vencerás". El objetivo no era tanto subir el kappa global como **mejorar la precisión diagnóstica por clase**, y en eso el Exp. D destaca: obtiene el **mejor F1 macro del proyecto** (0,631, empatado con A) y mejora notablemente G4 Proliferativa (0,59 frente al 0,51 del baseline), la clase clínicamente más crítica. Al separar el screening (G0 vs resto) de la gradación (G1–G4), cada submodelo ve un problema más equilibrado y especializado. Aunque el kappa queda ligeramente por debajo del preentrenamiento masivo (Exp. J), esta estructura es la **más eficaz para distinguir clases entre sí**.

4.4. Exp. C — BiomedCLIP zero-shot

Tipo de prompt	κ^2	F1 macro
Etiquetas simples	0,711	0,354
Descripciones clínicas	0,515	0,220

Las etiquetas simples funcionan mejor que las descripciones detalladas, pero en ambos casos los valores de F1 son muy bajos. Esto nos dice que para un problema médico de esta complejidad, el enfoque zero-shot no puede ofrecer la precisión que requiere un ajuste fino supervisado. El experimento confirma que **sí necesitamos entrenar un modelo específico** —como de hecho estamos haciendo— y descarta la vía del clasificador "listo para usar" sin entrenamiento.

4.5. Exp. F — 384 px + Regresión ordinal

$\kappa^2 = 0{,}872 \quad \text{F1} = 0{,}507$

Dejamos de tratar los grados como cubos aislados y empezamos a verlos como una **progresión continua**: una única neurona de salida, MSELoss y umbrales optimizados con Nelder-Mead. Se sube la resolución a 384 px para preservar detalles finos. El resultado en kappa es sólido y la matriz de confusión muestra un **buen desempeño en G2**, sugiriendo que ahora el modelo sí distingue microaneurismas y hemorragias que antes eran indistinguibles. Sin embargo, el mayor problema es grave: de 33 imágenes de

G4 Proliferativa en test, **el modelo solo detecta 3** (recall = 9,1 %, F1 = 0,158). La MSELoss con desbalance provoca una compresión hacia el centro que infradiagnostica la clase más peligrosa. Al analizar la interpretabilidad con Grad-CAM, se observa que el modelo activa correctamente sobre estructuras clínicas en varias imágenes, pero en otras persisten activaciones periféricas —un comportamiento mixto que motiva la intervención del Exp. G.

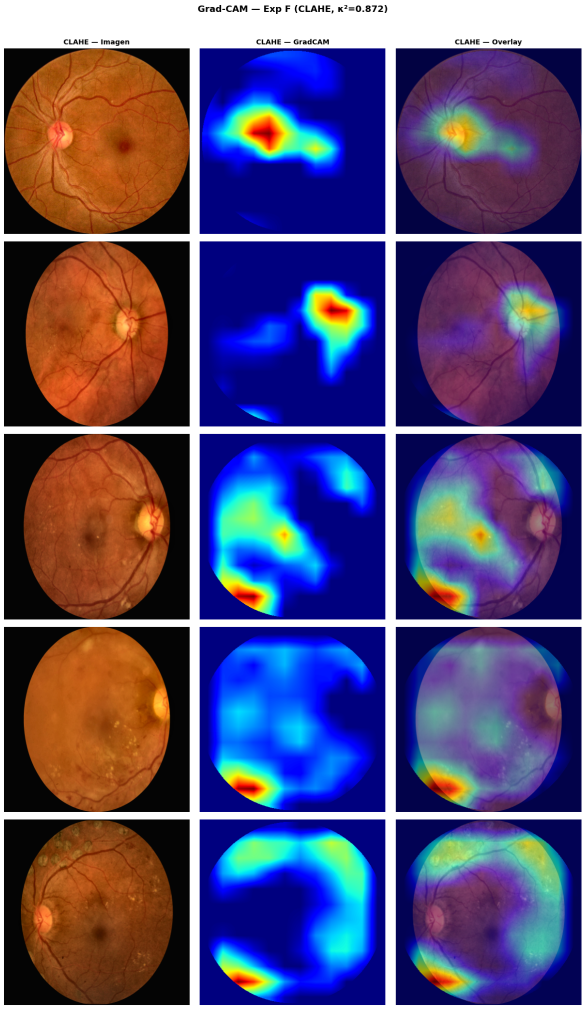

Figura 3. Visualización de Grad-CAM para el Experimento F.

4.6. Exp. G — Ben Graham + máscara dura

$\kappa^2 = 0{,}882 \quad \text{F1} = 0{,}575$

Se aplica el filtro de Graham —un filtro de paso alto que elimina la información de baja frecuencia, dejando bordes y texturas finas— junto con una máscara dura a nivel de tensor y augmentaciones puramente fotométricas. El kappa sube (+0,01 respecto a F), confirmando que la homogeneización de la iluminación entre dispositivos mejora la generalización. Sin embargo, la interpretabilidad con Grad-CAM empeora respecto al Exp. F: las activaciones se dispersan hacia la periferia del disco en lugar de

concentrarse sobre las lesiones. La explicación es que Grad-CAM visualiza la última capa convolucional, que opera a resolución muy baja (7×7), y a esa escala lo que domina son precisamente los bordes de alto contraste que Graham amplifica. Este resultado es el **hallazgo más importante del proyecto**: demuestra empíricamente que **un modelo con mejor métrica no es necesariamente un modelo más interpretable ni más fiable**.

4.7. Exp. B — Radiómica + Regresión Logística L1

$\kappa^2 = 0{,}722$ F1 = 0,479

Los resultados cuantitativos son modestos, pero el valor del experimento no reside en ellos: reside en la **interpretabilidad**. Los coeficientes L1 supervivientes (82 de 83 features con $C = 3$) demuestran que en las retinografías **sí existen patrones geométricos y de contraste estadísticamente significativos** para la gradación. Por ejemplo, para G3 los coeficientes más altos corresponden a `firstorder_10Percentile` (negativo: las hemorragias bajan la intensidad mínima) y `glrlm_HighGrayLevelRunEmphasis` (positivo: los exudados producen rachas brillantes). Este diccionario feature→significado clínico es imposible de extraer del CNN.

4.8. Exp. I — Fusión CNN + Radiómica

$\kappa^2 = 0{,}855$ (LightGBM) F1 = 0,631 (LightGBM)

Al fusionar 1 536 deep features del Exp. G con las 107 radiómicas, los resultados revelan información clara sobre **qué es realmente valioso para diagnosticar RD**: el 96,5 % de la aportación relativa proviene de la CNN. Sin embargo, al mirar el F1 macro (0,631) comprobamos que mejora sustancialmente respecto al Exp. B (0,479) y al Exp. C (0,354). La inclusión de características radiómicas ayuda al modelo a ser **más preciso en las clases difíciles** (G1, G3) donde antes dudaba más.

4.9. Exp. J — Preentrenamiento con APTOS 2015

$\kappa^2 = \mathbf{0{,}885}$ F1 = 0,551

Mejor kappa del proyecto. La estrategia es directa: preentrenar 20 épocas en las 35 k imágenes de APTOS 2015 y fine-tunear en 2019 con LR reducida (2×10^{-5}). Lo revelador es que desde la primera época de fine-tuning el modelo ya alcanza $\kappa^2 = 0{,}883$: no está intentando entender qué es una retina —eso ya lo aprendió con las 35 k imágenes— sino que está **ajustando los detalles específicos** del dataset de 2019. Además, mejora la detección de G4 Proliferativa con un recall del 27,3 %: puede parecer bajo en términos absolutos, pero es un progreso enorme respecto al 9,1 % del Exp. F. Este modelo es mucho más **resiliente** frente a la variabilidad de las imágenes, precisamente porque ha

visto una diversidad real de dispositivos y centros durante el preentrenamiento.

4.10. Comparativa final

Cuadro 4. Comparativa global ordenada por κ^2 en test.

Exp.	Técnica	κ^2	F1
J	Pretrain APTOS 2015 → Fine-tune 2019	**0,885**	0,551
G	Ben Graham + máscara dura + aug. fotométricas	0,882	0,575
A	Sobremuestreo clases minoritarias	0,880	0,631
F	384 px + MSELoss + umbrales Nelder-Mead	0,872	0,507
Baseline	EfficientNet-B3 + Weighted CE (224 px)	0,862	0,602
D	Binario RD+/RD− + Severidad G1–G4	0,860	**0,631**
E	Jerárquico 3 niveles	0,855	0,602
I	Deep feats + Radiómica → LightGBM	0,855	0,631
B	PyRadiomics + LR L1	0,722	0,479
C	BiomedCLIP zero-shot (prompts genéricos)	0,711	0,354

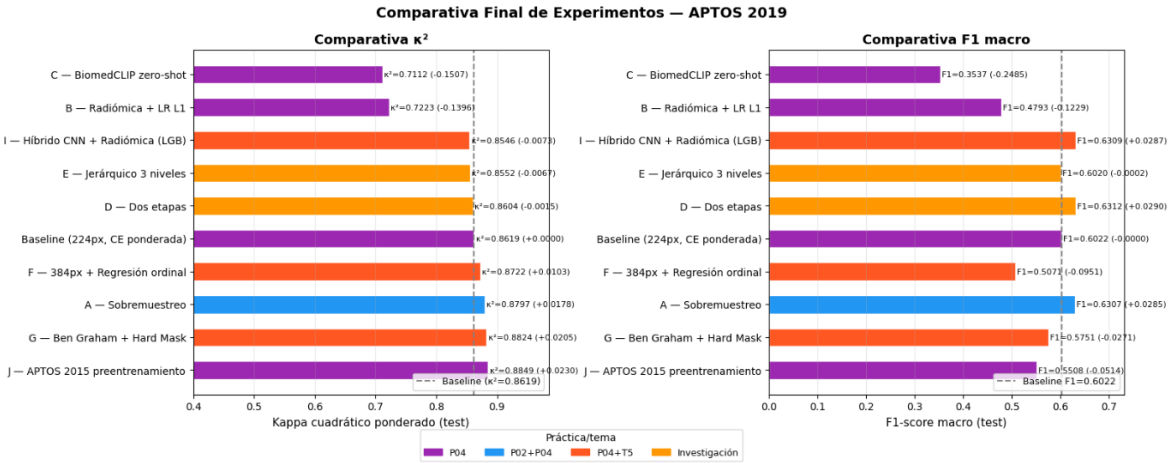

Figura 4. Comparativa Final de Experimentos.

5. Conclusiones y vías futuras

5.1. Conclusiones

El proyecto ha construido un pipeline completo de gradación automática de retinopatía diabética, partiendo de un baseline sólido ($\kappa^2 = 0{,}862$) y explorando diez experimentos que atacan sus limitaciones de forma iterativa. Las principales lecciones son:

1. **El desbalance necesita variedad, no volumen.** Replicar datos (Exp. A) apenas mejora G3; incorporar 35 k imágenes reales (Exp. J) sí funciona ($\kappa^2 = 0{,}885$).
2. **Dividir el problema ayuda.** El pipeline jerárquico (Exp. D) logra el mejor F1 macro y la mayor mejora en G4, la clase más crítica.
3. **Métrica alta $\neq$ modelo fiable.** El Exp. G sube κ^2 pero empeora Grad-CAM respecto a F: la auditoría de interpretabilidad es tan necesaria como la evaluación cuantitativa.
4. **El entrenamiento específico es imprescindible.** Radiómica (B) y zero-shot (C) quedan 14–15 puntos por debajo del CNN, pero B aporta interpretabilidad que el CNN no puede ofrecer.

5.2. Limitaciones

- **Tiempo y cómputo.** No se pudo ejecutar el baseline a 384 px ni probar más épocas, lo que habría aislado mejor el efecto de la resolución frente al de la regresión ordinal.
- **Interpretabilidad solo cualitativa.** Grad-CAM se evalúa por inspección visual; falta una métrica objetiva sobre lesiones anotadas.
- **Sin validación externa.** Todos los resultados provienen de APTOS 2019; la generalización a otros centros y equipos queda sin cuantificar.

5.3. Vías futuras

- Fine-tuning diferencial (congelar capas iniciales) y backbones más recientes (ConvNeXt, EfficientNetV2).
- Resolución de 448–512 px para preservar microlesiones de G1.
- Interpretabilidad cuantitativa mediante *pointing game* sobre anotaciones de lesiones (IDRiD).

Bibliografía

[1] International Diabetes Federation, *IDF Diabetes Atlas, 10th edition*, https://diabetesatlas.org/, Accedido en abril de 2026, 2023.

[2] World Health Organization, *Diabetes — Key facts*, https://www.who.int/news-room/fact-sheets/detail/diabetes, Accedido en abril de 2026, 2023.

[3] C. P. Wilkinson et al., "Proposed International Clinical Diabetic Retinopathy and Diabetic Macular Edema Disease Severity Scales," *Ophthalmology*, vol. 110, n.º 9, págs. 1677-1682, 2003. DOI: 10.1016/S0161-6420(03)00475-5.

[4] J. Cohen, "Weighted kappa: Nominal scale agreement provision for scaled disagreement or partial credit," *Psychological Bulletin*, vol. 70, n.º 4, págs. 213-220, 1968. DOI: 10.1037/h0026256.

[5] Asia Pacific Tele-Ophthalmology Society, *APTOS 2019 Blindness Detection*, https://www.kaggle.com/c/aptos2019-blindness-detection, Competición Kaggle, licencia CC BY 4.0, 2019.

[6] M. Sokolova y G. Lapalme, "A systematic analysis of performance measures for classification tasks," *Information Processing & Management*, vol. 45, n.º 4, págs. 427-437, 2009. DOI: 10.1016/j.ipm.2009.03.002.

[7] M. D. Abràmoff, M. K. Garvin y M. Sonka, "Retinal Imaging and Image Analysis," *IEEE Reviews in Biomedical Engineering*, vol. 3, págs. 169-208, 2010. DOI: 10.1109/RBME.2010.2084567.

[8] R. J. Gillies, P. E. Kinahan y H. Hricak, "Radiomics: Images Are More than Pictures, They Are Data," *Radiology*, vol. 278, n.º 2, págs. 563-577, 2016. DOI: 10.1148/radiol.2015151169.

[9] J. J. M. van Griethuysen et al., "Computational Radiomics System to Decode the Radiographic Phenotype," *Cancer Research*, vol. 77, n.º 21, e104-e107, 2017. DOI: 10.1158/0008-5472.CAN-17-0339.

[10] V. Gulshan, L. Peng, M. Coram et al., "Development and Validation of a Deep Learning Algorithm for Detection of Diabetic Retinopathy in Retinal Fundus Photographs," *JAMA*, vol. 316, n.º 22, págs. 2402-2410, 2016. DOI: 10.1001/jama.2016.17216.

[11] D. S. W. Ting, C. Y.-L. Cheung, G. Lim et al., "Development and Validation of a Deep Learning System for Diabetic Retinopathy and Related Eye Diseases Using Retinal Images From Multiethnic Populations With Diabetes," *JAMA*, vol. 318, n.º 22, págs. 2211-2223, 2017. DOI: 10.1001/jama.2017.18152.

[12] M. Tan y Q. V. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," en *International Conference on Machine Learning (ICML)*, 2019, págs. 6105-6114.

[13] M. J. Cardoso, W. Li, R. Brown et al., "MONAI: An Open-Source Framework for Deep Learning in Healthcare," *arXiv preprint arXiv:2211.02701*, 2022. dirección: `https://arxiv.org/abs/2211.02701`.

[14] B. Graham, *Kaggle Diabetic Retinopathy Detection competition report*, `https://kaggle.com/c/diabetic-retinopathy-detection/discussion/15801`, Solución ganadora, primer puesto, 2015.

[15] C. Beckham y C. Pal, "Unimodal Probability Distributions for Deep Ordinal Classification," en *International Conference on Machine Learning (ICML)*, 2017, págs. 411-419.

[16] W. Cao, V. Mirjalili y S. Raschka, "Rank consistent ordinal regression for neural networks with application to age estimation," *Pattern Recognition Letters*, vol. 140, págs. 325-331, 2020. DOI: `10.1016/j.patrec.2020.11.008`.

[17] S. Zhang et al., "BiomedCLIP: a multimodal biomedical foundation model pretrained from fifteen million scientific image-text pairs," *arXiv preprint arXiv:2303.00915*, 2023. dirección: `https://arxiv.org/abs/2303.00915`.

[18] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh y D. Batra, "Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization," en *IEEE International Conference on Computer Vision (ICCV)*, 2017, págs. 618-626. DOI: `10.1109/ICCV.2017.74`.

[19] R. Geirhos et al., "Shortcut Learning in Deep Neural Networks," *Nature Machine Intelligence*, vol. 2, n.º 11, págs. 665-673, 2020. DOI: `10.1038/s42256-020-00257-z`.

[20] G. Ke et al., "LightGBM: A Highly Efficient Gradient Boosting Decision Tree," en *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017, págs. 3146-3154.

A. Tabla de contribución individual

Cuadro 5. Distribución de tareas entre los miembros del grupo.
R = responsable principal, **P** = participó.

Tarea	Javier G.	Miguel Á. V.	Martín S.
Exploración del dataset (EDA)	R	P	P
Preprocesamiento (máscara, CLAHE)	R	P	P
Dataset class y aumentación	R	P	P
Baseline (EfficientNetBN-B3)	R	P	P
Exp. A — Sobremuestreo	P	R	P
Exp. B — Radiómica + LR L1	P	P	R
Exp. C — BiomedCLIP zero-shot	P	P	R
Exp. D — Pipeline dos etapas	P	R	P
Exp. E — Jerárquico tres niveles	P	R	P
Exp. F — 384 px + Regresión ordinal	P	R	P
Exp. G — Ben Graham + Hard Mask	P	P	R
Interpretabilidad Grad-CAM	P	P	P
Exp. I — Híbrido CNN + Radiómica	P	P	R
Exp. J — Pretrain APTOS 2015	P	P	R
Redacción de la memoria	P	P	P
Preparación de la defensa	P	P	P