Clasificación Automática de Retinopatía Diabética

Pipeline Completo de Clasificación por Gradación de Severidad

Asignatura: Procesamiento y Análisis de Imagen Médica (PIM)

Curso académico: 2025 – 2026

Fecha de entrega: 24 de abril de 2026

Integrantes del grupo

Javier García Fernández

Miguel Ángel Véliz Ayala

Martín Solano Martínez

Resumen

Este trabajo aborda la clasificación automática de la retinopatía diabética (RD) en cinco grados de severidad clínica —desde grado 0 (sin RD) hasta grado 4 (proliferativa)— a partir del dataset público APTOS 2019. Se construye un pipeline completo basado en EfficientNetBN-B3 (MONAI) con preprocesamiento específico para retinografías mediante máscara circular y CLAHE, y se diseñan y comparan diez experimentos que abordan las principales limitaciones del modelo base: desbalance de clases (Exp. A), radiómica cuantitativa con PyRadiomics (Exp. B), clasificación zero-shot con BiomedCLIP (Exp. C), pipelines jerárquicos (Exp. D y E), regresión ordinal a 384 px con optimización de umbrales (Exp. F), corrección de *shortcut learning* mediante preprocesado Ben Graham (Exp. G), fusión multimodal CNN + radiómica con LightGBM (Exp. I) y preentrenamiento en APTOS 2015 (Exp. J). La métrica principal es el kappa cuadrático ponderado (κ^2), estándar en la literatura de gradación automática de RD. Los resultados completos y el análisis comparativo de todos los experimentos se presentan en la Sección 4.

Índice

Resumen **i**

Índice **ii**

1. Introducción **1**

2. Estado del arte **2**

3. Objetivos y metodología **2**

4. Resultados **3**

5. Conclusiones y vías futuras **3**

A. Tabla de contribución individual **4**

1. Introducción

La **retinopatía diabética** (RD) es una complicación microvascular de la diabetes mellitus y una de las principales causas de ceguera prevenible en el mundo. Con más de 540 millones de adultos diabéticos estimados en 2023 y una prevalencia de afectación retiniana en torno al 35 % de los pacientes **idf2023**, **who2023**, el cribado masivo mediante retinografías de fondo de ojo es una necesidad clínica de primer orden. Sin embargo, la revisión manual de miles de imágenes por oftalmólogos resulta inviable a gran escala, lo que motiva el desarrollo de sistemas automáticos de gradación.

La enfermedad progresa en cinco estadios (Tabla 1): desde la ausencia de lesiones (G0) hasta la neovascularización proliferativa con riesgo de ceguera súbita (G4), pasando por microaneurismas aislados (G1), hemorragias y exudados duros (G2) y afectación vascular extensa en los cuatro cuadrantes (G3). Esta naturaleza ordinal del problema, junto con el severo desbalance de clases del dataset —G0 representa ∼49 % del entrenamiento frente al ∼5 % de G3—, la ambigüedad entre grados adyacentes, la pérdida de detalles finos al comprimir las imágenes a baja resolución y el riesgo de *shortcut learning* sobre artefactos de adquisición, conforman los desafíos técnicos que este proyecto aborda de forma sistemática.

Cuadro 1. Escala de severidad de la retinopatía diabética.

Grado	Nombre	Características clínicas
0	Sin RD	Fondo de ojo normal. Sin lesiones visibles.
1	Leve	Microaneurismas aislados.
2	Moderada	Hemorragias, exudados duros y anomalías vasculares.
3	Severa	Múltiples hemorragias, *venous beading* e IRMA en los cuatro cuadrantes.
4	Proliferativa	Neovascularización con riesgo de hemorragia vítrea y desprendimiento de retina.

El objetivo del proyecto es construir un pipeline reproducible y clínicamente interpretable que parta de un baseline sólido (EfficientNetBN-B3, APTOS 2019, 224 px) y lo mejore de forma justificada mediante diez experimentos que atacan cada una de las debilidades identificadas. La métrica principal es el **kappa cuadrático ponderado** (κ^2), que penaliza los errores proporcionalmente al cuadrado de la distancia ordinal entre grados, alineándose con la relevancia clínica de cada tipo de error. La elección de la RD como problema de estudio responde, además, a la disponibilidad de datos públicos

de calidad (licencia CC BY 4.0) y a que su naturaleza permite aplicar directamente las técnicas del curso: preprocesamiento de imagen médica, aprendizaje profundo con MONAI, radiómica cuantitativa e interpretabilidad con Grad-CAM.

Figura 1. Retinografías representativas por grado de severidad (G0–G4). Las diferencias entre grados adyacentes son sutiles, lo que dificulta la gradación manual a gran escala.

El resto del documento se organiza del siguiente modo: la Sección 2 revisa el estado del arte; la Sección 3 describe los objetivos, el dataset y el pipeline; la Sección 4 presenta los resultados; y la Sección 5 recoge las conclusiones y vías futuras.

2. Estado del arte

► ***[PENDIENTE]:*** *Sección a cargo de Miguel Ángel y/o Martín.*
Estructura sugerida: (2.1) métodos clásicos basados en segmentación y radiómica, (2.2) redes convolucionales profundas para gradación de RD, (2.3) modelos visión-lenguaje y zero-shot, (2.4) radiómica y fusión multimodal.
Referencias clave: Gulshan et al. (2016), Tan & Le EfficientNet (2019), BiomedCLIP Zhang et al. (2023), Ting et al. (2017).

3. Objetivos y metodología

► ***[PENDIENTE]:*** *Sección a cargo del grupo.*
Incluir: (3.1) objetivos concretos y medibles, (3.2) descripción del dataset APTOS 2019 y APTOS 2015 (fuente, tamaño, modalidad, licencia, distribución de clases), (3.3) diagrama del pipeline con justificación de cada decisión de diseño (máscara circular, CLAHE, Ben Graham, EfficientNetBN-B3, regresión ordinal, etc.), (3.4) tabla resumen de los diez experimentos.

4. Resultados

► ***[PENDIENTE]:*** *Rellenar la tabla y el análisis con los valores de κ^2 y F1 macro obtenidos en la ejecución del notebook (Baseline, Exp. A–G, I y J).*

5. Conclusiones y vías futuras

► ***[PENDIENTE]:*** *Sección a cargo del grupo.*
Incluir: (5.1) hallazgos principales (qué experimento gana y por qué), (5.2) limitaciones honestas del trabajo, (5.3) mejoras concretas y líneas futuras.

A. Tabla de contribución individual

Cuadro 2. Distribución de tareas entre los miembros del grupo. **R** = responsable principal, **P** = participó.

Tarea	**Javier G.**	**Miguel Á. V.**	**Martín S.**
Exploración del dataset (EDA)			
Preprocesamiento (máscara, CLAHE)			
Dataset class y aumentación			
Baseline (EfficientNetBN-B3)			
Exp. A — Sobremuestreo			
Exp. B — Radiómica + LR L1			
Exp. C — BiomedCLIP zero-shot			
Exp. D — Pipeline dos etapas			
Exp. E — Jerárquico tres niveles			
Exp. F — 384 px + Regresión ordinal			
Exp. G — Ben Graham + Hard Mask			
Interpretabilidad Grad-CAM			
Exp. I — Híbrido CNN + Radiómica			
Exp. J — Pretrain APTOS 2015			
Redacción de la memoria			
Preparación de la defensa			